

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería de Transporte y Logística




Sistemas Urbanos Inteligentes

Redes de grafos convolucionales

Hans Löbel


Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación

No olvidemos lo que buscamos



Si queremos utilizar redes neuronales para parametrizar f , necesitamos que esta sea **differentiable**, **componible** y **escalable**.

Hacia dónde vamos




Notation: $\mathcal{G} = (\mathbf{A}, \mathbf{X})$

- Adjacency matrix $\mathbf{A} \in \mathbb{R}^{N \times N}$
- Feature matrix $\mathbf{X} \in \mathbb{R}^{N \times F}$

Idea principal: pasar mensajes entre nodos y combinarlos

Otra perspectiva más ML: pasar mensajes entre nodos para refinar la representación

Recordemos la idea detrás de las convoluciones



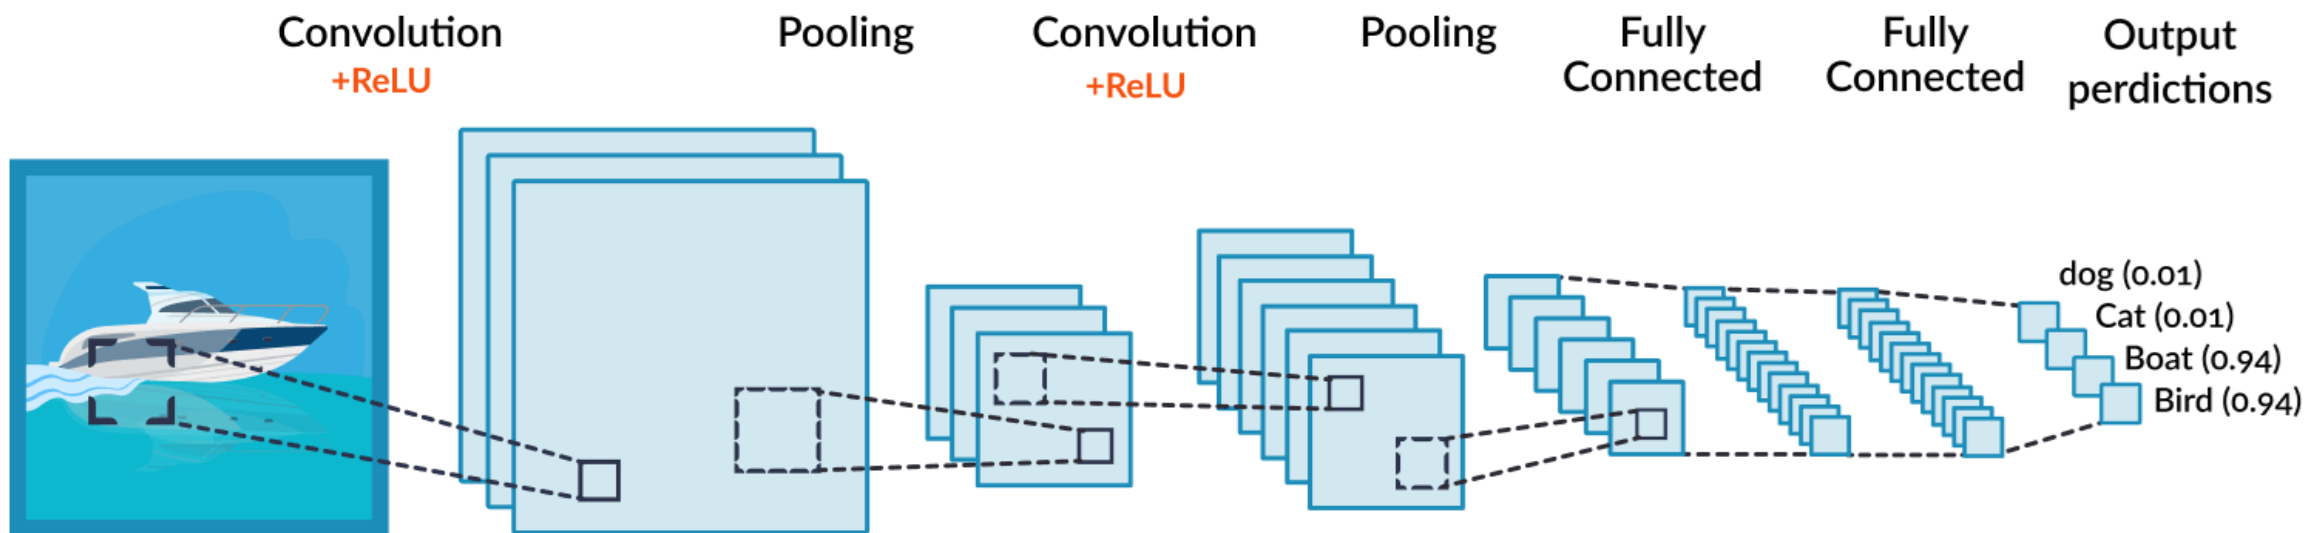
Recordemos la idea detrás de las convoluciones

$$f \left(\begin{array}{|c|c|c|c|} \hline \square & \square & \square & \square \\ \hline \square & \textcolor{blue}{\square} & \textcolor{blue}{\square} & \textcolor{blue}{\square} \\ \hline \square & \textcolor{blue}{\square} & \textcolor{red}{\square} & \textcolor{blue}{\square} \\ \hline \square & \textcolor{blue}{\square} & \textcolor{blue}{\square} & \textcolor{blue}{\square} \\ \hline \end{array} \right) = \mathbf{a}^T \textcolor{red}{\square} + \sum_{j \in \begin{array}{|c|c|c|} \hline \textcolor{blue}{\square} & \textcolor{blue}{\square} & \textcolor{blue}{\square} \\ \hline \textcolor{blue}{\square} & \textcolor{blue}{\square} & \textcolor{blue}{\square} \\ \hline \textcolor{blue}{\square} & \textcolor{blue}{\square} & \textcolor{blue}{\square} \\ \hline \end{array}} \mathbf{c}_j^T \textcolor{blue}{\square}$$

Operación local
(pixel central)

Agregación



Operación sobre
vecinos (resto de
los pixeles)



¿En qué se diferencian las imágenes de los grafos?

La clave es fijarse en la estructura local

- ✓ Localidad (vecindario)
- ✗ Tamaño del vecinario
- ✗ Orden del vecindario



Convoluciones en grafos (versión simplificada)

$$f\left(\begin{array}{c} \text{blue} \quad \text{red} \quad \text{blue} \\ | \quad / \quad \backslash \\ \text{white} \quad \text{blue} \\ | \quad / \\ \text{white} \end{array}\right) = W_0^T \text{red} + \sum_{j \in \begin{array}{c} \text{blue} \quad \text{white} \quad \text{blue} \\ | \quad / \quad \backslash \\ \text{blue} \end{array}} W_1^T \text{blue}$$




Operación local

Agregación

Operación sobre
vecinos usando
matriz de adyacencia


Es importante notar que acá solo podemos aprender una transformación que no depende del orden/posición del vecino

Convoluciones en grafos (versión simplificada)




Convoluciones en grafos (un poco menos simplificadas)

Consider this undirected graph:



Calculate update for node in red:



Desirable properties:

- Weight sharing over all locations
- Invariance to permutations
- Linear complexity $O(E)$
- Applicable both in transductive and inductive settings


Update rule:

$$\mathbf{h}_i^{(l+1)} = \sigma \left(\mathbf{h}_i^{(l)} \mathbf{W}_0^{(l)} + \sum_{j \in \mathcal{N}_i} \frac{1}{c_{ij}} \mathbf{h}_j^{(l)} \mathbf{W}_1^{(l)} \right)$$

Scalability: subsample messages [Hamilton et al., NIPS 2017]

\mathcal{N}_i : neighbor indices c_{ij} : norm. constant


¿Qué pasa si tenemos/queremos más capas?



Capas sucesivas amplían la “visión” del vecindario de cada nodo


¿Cómo se ve en la práctica una GCN?

Input: Feature matrix $\mathbf{X} \in \mathbb{R}^{N \times E}$, preprocessed adjacency matrix $\hat{\mathbf{A}}$



¿Cómo se ve en la práctica una GCN?

Input: Feature matrix $\mathbf{X} \in \mathbb{R}^{N \times E}$, preprocessed adjacency matrix $\hat{\mathbf{A}}$




Node classification:

$\text{softmax}(\mathbf{z}_n)$

e.g. Kipf & Welling (ICLR 2017)


¿Cómo se ve en la práctica una GCN?

Input: Feature matrix $\mathbf{X} \in \mathbb{R}^{N \times E}$, preprocessed adjacency matrix $\hat{\mathbf{A}}$



¿Cómo se ve en la práctica una GCN?

Input: Feature matrix $\mathbf{X} \in \mathbb{R}^{N \times E}$, preprocessed adjacency matrix $\hat{\mathbf{A}}$




También podemos hacer clasificación semi-supervisada

Setting:

Some nodes are labeled (black circle)
All other nodes are unlabeled

Task:

Predict node label of unlabeled nodes



Evaluate loss on labeled nodes only:


$$\mathcal{L} = - \sum_{l \in \mathcal{Y}_L} \sum_{f=1}^F Y_{lf} \ln Z_{lf}$$

\mathcal{Y}_L set of labeled node indices


\mathbf{Y} label matrix

\mathbf{Z} GCN output (after softmax)


Veamos como funciona esto



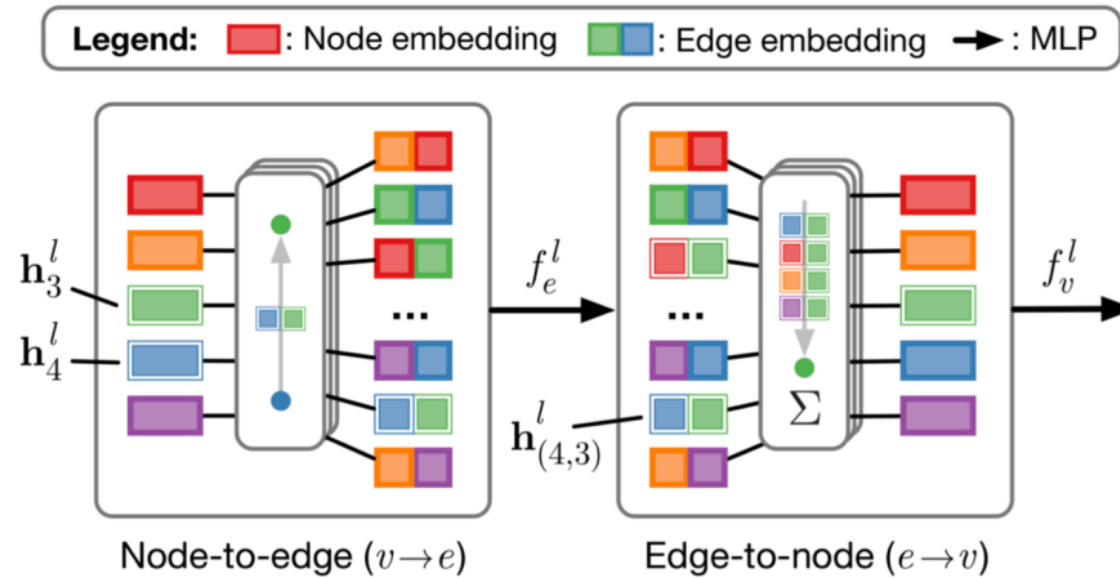
Veamos como funciona esto



Veamos como funciona esto



Podemos extender todo esto para calcular representaciones de arcos




Formally:

$$v \rightarrow e : \mathbf{h}_{(i,j)}^l = f_e^l([\mathbf{h}_i^l, \mathbf{h}_j^l, \mathbf{x}_{(i,j)}])$$

$$e \rightarrow v : \mathbf{h}_j^{l+1} = f_v^l([\sum_{i \in \mathcal{N}_j} \mathbf{h}_{(i,j)}^l, \mathbf{x}_j])$$




El problema es que resulta mucho más complejo

Y también podemos generalizarlo completamente



En vez de utilizar la matriz de adyacencia de forma directa, podemos pensar que los nodos intercambian mensajes de acuerdo a diversos mecanismos, por ejemplo, atención.

Y también podemos generalizarlo completamente



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería de Transporte y Logística



Sistemas Urbanos Inteligentes

Redes de grafos convolucionales

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación