



PONTIFICIA  
UNIVERSIDAD  
CATÓLICA  
DE CHILE

# Deep Architecture for Citywide Travel Time Estimation Incorporating Contextual Information

**MSc. José Edgardo Niño Báez**

Escuela de Ingeniería

Área de Ingeniería industrial y de Transporte

# Introducción

Estimar los tiempos de viaje:

- Permite a los conductores tomar mejores decisiones en las rutas
- Hace posible mejorar la eficiencia en el sistema de transporte



El tiempo de viaje se ve afectado por:


- Atributos de tipo geográfico
- Atributos de tipo contextual
- Segmentos de carretera vecinos
- La presencia de ruido en las señales



# Composición del Modelo

En el modelo propuesto, se introducen las siguientes características principales:

- Incorpora atributos de tipo geográfico
- Incorpora atributos de tipo contextual
- Tiene en cuenta el impacto de segmentos vecinos
- Utiliza un codificador para reducción de ruido
- Realiza entrenamiento de la red basado en aprendizaje por capas
- Tiene en cuenta datos etiquetados y no etiquetados
- Las capas ocultas utilizan aprendizaje no supervisado
- La última capa utiliza aprendizaje supervisado





# Atributos de tipo geográfico

Los atributos de tipo geográfico tomados en cuenta en el modelo son los siguientes:

- Longitud del segmento de la vía en estudio
- Número de carriles de la vía
- Máxima velocidad permitida
- Dirección de la vía
- Nivel de la vía
- Tortuosidad
- Conexión – Número de segmentos vecinos



SR-30

60

VELOCIDAD MÁXIMA

# Atributos de tipo contextual

Los atributos de tipo contextual tomados en cuenta en el modelo fueron los siguientes:

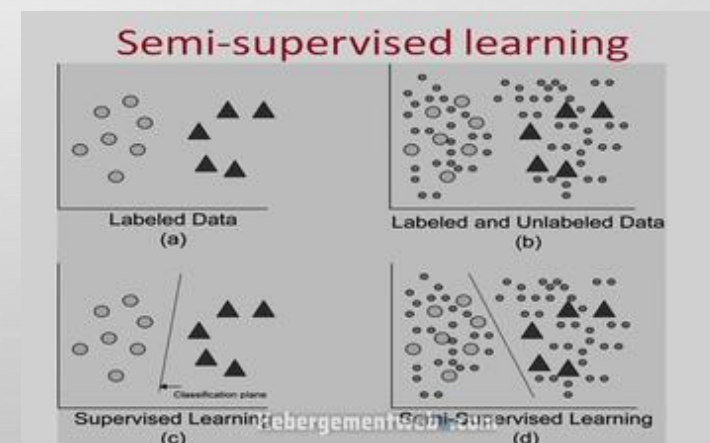
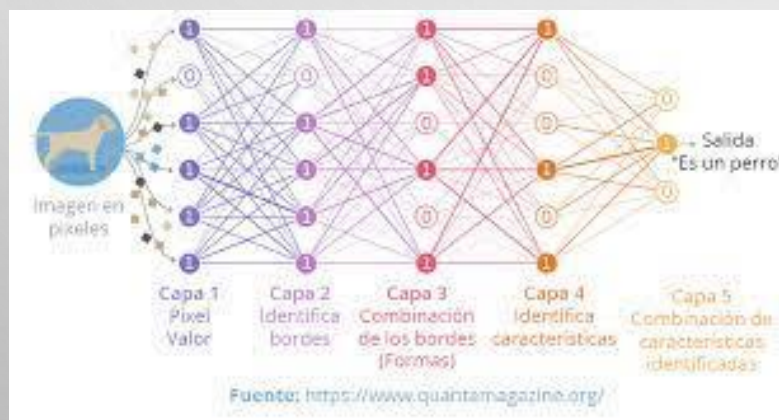
- Número de escuelas
- Número de empresas o lugares de trabajo
- Número de bancos o entidades financieras
- Número de supermercados o malls
- Número de tiendas de comida
- Número de estaciones de gasolina
- Número de lugares de interés turístico
- Número de hoteles o lugares de residencia
- Número de paradas de bus o estaciones de metro
- Número de lugares de entretenimiento
- Número de POI's alrededor del segmento





# Deep Learning

- Realiza procesos de Machine Learning usando una red neuronal artificial que se compone de un número de niveles jerárquicos.
- Aprendizaje por capas o niveles, en donde a medida que se aumenta de nivel se toma como base el conocimiento anterior para otro conocimiento más complejo.
- La principal ventaja es que esta forma de aprendizaje funciona bien para datos no etiquetados, que son datos de más fácil acceso.



# Algoritmo del modelo realizado

La forma del algoritmo utilizado es la siguiente:

$$\mathbf{x}(i) = [x_1(i), x_2(i), \dots, x_d(i)] = [\mathbf{g}(i - m), \mathbf{c}(i - m), \dots, \mathbf{g}(i), \mathbf{c}(i), \dots, \mathbf{g}(i + m), \mathbf{c}(i + m)] \quad (1)$$

En donde  $\mathbf{g}(i)$  son las características geográficas utilizadas en el modelo:

$$\mathbf{g}(i) = [g_1(i), g_2(i), \dots, g_7(i)] \quad (2)$$

En donde  $\mathbf{c}(i)$  son las características contextuales utilizadas en el modelo:

$$\mathbf{c}(i) = [c_1(i), c_2(i), \dots, c_{11}(i)] \quad (3)$$



# Algoritmo del modelo realizado

$$d = (2m + 1) \times (7 + 11) = 36 \times m + 18 \quad (4)$$





m= Cantidad de segmentos vecinos considerados en el análisis

$$t = \mathcal{F}(\mathbf{x}(i)) \quad (5)$$

t= Tiempo de viaje de un nuevo segmento



# Algoritmo del modelo realizado



# Especificaciones del modelo



Las ventajas de este modelo se fundamentan en los siguientes métodos:

- Back Propagation Neural Network (BPNN): Se demuestra la ventaja de la arquitectura profunda y pre – entrenamiento no supervisado.
- Stacked Auto-Encoder without unlabeled data (SAE1): Arquitectura profunda compuesta de varias capas ocultas que son pre-entrenadas, solamente con datos etiquetados.
- Stacked Auto-Encoder with unlabeled data (SAE2): Muestra la efectividad de utilizar datos no etiquetados para mejorar la precision de estimación.
- Stacked Sparse Auto-Encoder (SSAE): Muestra la contribución del aprendizaje de representación dispersa.
- Stacked Sparse Denoising Auto – Encoder (SSDAE): Muestra la importancia de tratamiento del ruido en el modelo.

# Resultados Obtenidos

- Se encontró más alta precisión en la estimación del tiempo de viaje, con respecto a los modelos competitivos de otros autores, debido a que reúne: arquitectura profunda, uso de datos no etiquetados, aprendizaje de atributos dispersos y tratamiento de ruido.
- Se realizaron varios modelos, variando el número de segmentos vecinos del segmento bajo análisis y teniendo en cuenta características geográficas y contextuales. Se obtuvo que algunas características pueden desmejorar la precisión del modelo cuando se agregan al mismo, pero en general a mayor información, mayor precisión en la estimación del tiempo de viaje.



# Conclusiones

- Este artículo desarrolló una arquitectura profunda para estimar el tiempo de viaje sobre un segmento de Carretera en una red de transporte urbano de una perspectiva de ciudad entera, incorporando atributos geográficos, contextuales y de correlación de vecindad especial.
- El modelo desarrollado, utilizó un algoritmo de aprendizaje semi- no supervisado de entrenamiento por capas.
- Como trabajo a futuro se propuso el ensamble de varios modelos para conjuntos de datos con diferentes hipótesis para mejorar la precisión de la estimación del tiempo de viaje.

# Enlaces de Interés

- <https://www.smartpanel.com/que-es-deep-learning/>
- <https://youtu.be/1gG3QiZ08IU>
- <https://youtu.be/oT3arRRB2Cw>